


LLM エージェントのセキュリティ:脆弱性と防御手法

電気通信大学 学域4年 藤原大己

1 自立して考え動く、LLMエージェント

LLM（大規模言語モデル）とは
自然言語を処理し、対話形式で文章を生成
ChatGPTやClaudeのことをLLMと言う
初期のLLMはユーザの質問に返答するだけ

LLMエージェント
ツールを使用して情報を収集したり
コンピュータを操作できる
自律してユーザーの業務を代行



2 解決すべきセキュリティの問題

課題① ジェイルブレイク

悪意のあるユーザが、LLMに有害な生成をさせる。

事前学習とは


膨大なデータから知識を得ること。
このデータの中には有害なものが混ざってしまう
(暴力、危険物の生成...)

アライメント(整合性)とは

LLMの有害な生成を防ぐ訓練
LLMの倫理に従う能力を向上

ジェイルブレイクとは

LLMのアライメントをすり抜けること
脱獄攻撃ともいう



課題② IPI（間接プロンプトインジェクション）

ハッカーが外部データに、悪意ある命令を注入する。

外部データの利用とは


事前学習だけでは答えられない
質問に対応したい
外部データを検索し、情報を補う
(明日の天気、為替...)

ツール呼び出しとは

LLMエージェントがツールを呼び出す
LLMがコンピュータを操作する
(検索エンジン, Gmail...)

IPIとは

攻撃者がユーザの命令を乗っ取る
外部データに悪意ある命令を注入



3 IPIの詳細

IPI(間接プロンプトインジェクション)とは...

LLM Agentへのハッキング

2023年にKai Greshakeらの論文により提唱された、LLM エージェントへの攻撃


LLM Agentが取得する外部データの中に、
攻撃者が秘密裏にLLMへの命令(プロンプト)を注入(インジェクション)
外部データの中に悪意ある命令を潜ませ間接的に注入

LLMの構造的脆弱性

LLMは「ユーザの命令」と「取得した情報」を線引きできない

LLMは、入力データを全てひとつながりの情報として処理

「これは信頼していいユーザの命令」、「これはただの外部情報」という境界線が無い
文章の中に命令っぽいものがあると、誤ってそれに従う



Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection [Kai Greshake](#) 2023

4 既存の防御手法

命令とデータを区別

- 命令と、外部データを区切る
- ユーザーの指示を貼り直し、LLMに注意喚起

悪意ある命令を検出

- 注入攻撃を検出するAIで外部データをチェック

別のLLMが監視


- LLM Agentの行動が正常かを別のLLMが監視

ツール利用の権限を制限

- LLMにツールを利用させない
- 人間が逐次許可

5 IPIGuard（先行研究）

キーワード: 先に計画、後で実行



IPIGUARD: A Novel Tool Dependency Graph-Based Defense Against Indirect Prompt Injection in LLM Agents [Hengyu An](#) 2025