

LLMエージェントのセキュリティ： ソフトウェアテストの観点からの考察

電気通信大学 ○藤原 大己 趙 振江 戸田貴久

SES2026 WS4: AI・機械学習システムの品質保証と信頼性

目次

1. **LLM**エージェントのセキュリティに関する研究解説
2. ソフトウェアテストの観点からの考察

第 1 部

LLMエージェントの セキュリティに関する研究解説

参考文献

- [1] Anthropic, Building Effective Agents,
<https://www.anthropic.com/engineering/building-effective-agents> ,2024
- [2] Fábio Perez et al, "Ignore Previous Prompt: Attack Techniques For Language Models", NeurIPS, 2022
- [3] Kai Greshake et al, "Not what you've signed up for: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection", AISec, 2023
- [4] OWASP, OWASP GenAI LLM Top 10 2026, <https://genai.owasp.org/resource/owasp-genai-llm-top-10-2026/> ,2026
- [5] Yulin Chen et al, "Can Indirect Prompt Injection Attacks Be Detected and Removed?", ACL main, 2025
- [6] Microsoft, "Defending Against Indirect Prompt Injection Attacks With Spotlighting", arXiv:2403.14720, 2024

[7] Eric Wallace, "The Instruction Hierarchy: Training LLMs to Prioritize Privileged Instructions", OpenAI, 2024

[8] Qiusi Zhan et al, Adaptive Attacks Break Defenses Against Indirect Prompt Injection Attacks on LLM Agents, NAACL Findings, 2025


[9] Hengyu An et al, IPIGuard: A Novel Tool Dependency Graph-Based Defense Against Indirect Prompt Injection in LLM Agents, EMNLP Oral, 2025 ★

[10] Edoardo DeBenedetti et al, AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents, NeurIPS Poster, 2024 ★

[11] Rishika Bhagwatkar et al, Indirect Prompt Injections: Are Firewalls All You Need, or Stronger Benchmarks?, <https://arxiv.org/html/2510.05244v1>, arXiv, 2025

LLMエージェントは、拡張LLMをループさせるソフトウェア [1]


LLMが入力（指示文、ツールと環境の情報）から、次に必要なツール呼び出しを判断する
拡張LLMがタスク終了まで繰り返し呼び出される



プロンプトインジェクションはユーザのプロンプトを後から乗っ取る [2]

ユーザの正常なプロンプトを、後から注入した指示で不正に乗っ取る


LLMは外部データとユーザからのプロンプトを区別せず、同一の入力として処理するアーキテクチャの問題であり、修正が困難



間接プロンプトインジェクション(IPI)は LLMエージェントの課題である [3][4]

不正なプロンプトをLLMに間接的に注入する

動作元 ●ユーザー ●LLMエージェント ●攻撃者



IPIの防御手法は複数あるが発展途上


防御手法のアプローチは複数に分類される

- 入力のサニタイズ [5]
取得した外部データから、不正な指示文を削除
- システムプロンプトの強化 [6]
外部データやユーザの指示文を特殊文字で区切り、判別しやすくする
- **LLM**のアライメント向上 [7]
LLMの出力を倫理観に沿った、安全なものにするために事後学習する

各防御手法に対する適応的攻撃も存在する [8]

IPIGuard: ツールの計画と外部データを分離する手法 [9]

ツール呼び出しの計画(TDG)を作成し、実行時のツール呼び出しを制限



AgentDojo:主要な論文で採用されている評価フレームワーク [10]

多くの防御手法で**AgentDojo**がベンチマークとして採用されている
テストケースは以下の組み合わせ

- タスクスイート
ユーザの指示と攻撃者の指示のペア(97のユーザタスクと27の攻撃タスク)
- 環境
LLMエージェントが取得できる外部データと利用できるツール
(Workspace,Slack,Banking,Travel)
- 攻撃手法と防御手法
テストしたい手法を組み込む(デフォルトでは防御攻撃が4つずつ)

AgentDojoで測定できる数値

指標	意味
UA (Utility under Attack)	攻撃下で正規タスクを達成できたか（有用性）
ASR (Attack Success Rate)	攻撃者のタスクが実行されたか（安全性）

防御手法は**AgentDojo**で高**UA**と低**ASR**を達成することを目指している

まとめ

- **LLM**エージェントとは、**LLM**を組み込んだソフトウェアである
- **IPI**は重大な**LLM**のセキュリティの脅威である
- 防御手法と攻撃手法は、ベンチマークによって評価されている

第 2 部

ソフトウェアテストの 観点からの考察

ソフトウェアテストとは

開発したプログラムが仕様どおりに動くかを確認し、不具合を見つけ出すテスト

Example-based Testing (EBT)

テストケースとなるペアを1つずつ用意

`assert max(2, 1) == 2` OK

`assert max(1, 5) == 5` OK

`assert max(3, 3) == 3` OK



弱点
想定外のケースの見落としが生じる

Property-based Testing (PBT)

「ソフトウェアが満たすべき性質」を書き、
テストケースとなるペアは自動生成する

性質 (Property) : 任意の a, b について
 $\max(a, b) \geq a$ かつ $\max(a, b) \geq b$ 、結果は a か b に等しい


ツールが入力をランダムに大量生成
(2, 1) · (0, 0) · (-7, 12) · (999, -999) ...



利点
想定外の入力もテストすることができ、見落としが減る

AgentDojoをソフトウェアテストと捉える

AgentDojoはEBTかつセキュリティテストとみなせる



AgentDojoのソフトウェアテストとしての課題 [10][11]

AgentDojoがテストしようとしていないもの

- マルチモーダルな入力を受け取るLLMAgent
- 実OSと実Webを操作するツールの権限を持つLLMAgent
- 記憶を引き継いだ状態での連続的なタスク実行

これらは**AgentDojo**のスコープ外なので別のベンチマークでテストする

AgentDojoのソフトウェアテストとしての課題 [10][11]

AgentDojo自身が定義する前提条件のもとであっても、
用意されているテストケースが十分な網羅性を持たないという点
実世界におけるAgentの利用領域は無数に存在するのに対し、AgentDojoが用意するテストケースはわずか629個にとどまる。

↓

単純な防御手法で低い**ASR**を達成できてしまう [11]

↓

テストケースを拡張すべきである

防御手法を正しく評価するには強力な攻撃手法と、十分なテストケースが必要

↓

防御手法が効かないエッジケースを**AgentDojo**に追加しテスト範囲を拡大する
IPIGuardは攻撃者のタスクとユーザのタスクが重複するタスクスイート、
読み取りのみを目的とした攻撃タスクで攻撃が成功しやすい